

Operaciones de aprendizaje automático

Actividad Individual | Código de experimentación base con MLFlow

Iván Reyes Amezcua

Jorge David Alcázar Rochín- A01252855

11 de octubre del 2026

1. Descripción del trabajo

El modelo base que se entrenó en el notebook de la actividad anterior se convirtió en un script de Python ejecutable desde la línea de comandos. El notebook se conserva únicamente para la exploración de datos y toda la lógica de carga, limpieza, entrenamiento, evaluación y registro vive ahora en train.py, organizada en funciones con una responsabilidad cada una: cargar_datos, limpiar_datos, construir_modelo, evaluar, guardar_artefactos y registrar_modelo.

El problema sigue siendo de regresión: predecir el overall rating de un jugador del dataset EA SPORTS FC 27 a partir de sus atributos. Para poder variar hiperparámetros se incorporó un Random Forest, dejando la regresión lineal de la actividad anterior disponible como punto de comparación dentro del mismo experimento.

2. Repositorio

El código, las dependencias y las instrucciones de ejecución están en:

```
https://github.com/jorgealcazarrochin/TC5061.10---A01252855
```

3. Ejecución del script

El script corre con valores por defecto sin pasar ningún argumento, y expone como argumentos de línea de comandos tres hiperparámetros del modelo más la semilla aleatoria. El comando exacto de la corrida con mejor desempeño es:

```
python train.py --model random_forest --n-estimators 300 --seed 42
```

Las cinco configuraciones de esta actividad se ejecutan con:

```
bash run_experiments.sh
```

Los argumentos disponibles se consultan con python train.py --help. Todas las corridas quedan agrupadas en el experimento fc27_experimentacion, con SQLite como backend de tracking.

4. Corridas realizadas

Corrida	Configuración	MAE	RMSE	R^2
1	linear (baseline)	1.9082	2.4079	0.8755
2	RF, 100 árboles	0.9248	1.1977	0.9692
3	**RF, 300 árboles**	**0.9184**	**1.1891**	**0.9696**
4	RF, 300, max_depth 8	1.1427	1.4709	0.9535
5	RF, 300, min_samples_leaf 10	0.9750	1.2718	0.9653

5. Análisis de resultados

La mejor configuración fue la corrida 3 (Random Forest con 300 árboles, sin límite de profundidad), con un MAE de 0.9184 puntos de rating y un R^2 de 0.9696. Frente al baseline lineal, el error promedio se reduce a menos de la mitad: de equivocarse por 1.91 puntos pasa a equivocarse por 0.92. Como referencia adicional, un modelo que siempre predice la media tiene un MAE de 5.32, así que el baseline ya aportaba y el Random Forest aporta todavía más.

El hiperparámetro más influyente fue max_depth. Limitar la profundidad a 8 niveles (corrida 4) empeoró el MAE de 0.9184 a 1.1427, un 24% peor, siendo el único cambio que mueve el resultado de forma notoria. Le sigue min_samples_leaf: subirlo a 10 (corrida 5) degradó el error un 6%. En contraste, n_estimators resultó casi irrelevante: triplicar los árboles de 100 a 300 (corridas 2 y 3) mejoró el MAE apenas 0.0064, una diferencia que no justifica el triple de tiempo de entrenamiento. Esto tiene sentido porque los dos primeros hiperparámetros controlan qué tanto puede aprender cada árbol, mientras que el tercero solo promedia más árboles que ya son parecidos entre sí.

Las limitaciones del ejercicio son varias. Las métricas provienen de una sola división entrenamiento-prueba, por lo que una diferencia de centésimas entre corridas puede deberse al azar de esa partición y no a la configuración; una validación cruzada daría una comparación más confiable. Tampoco se evaluó el sobreajuste: la corrida ganadora deja crecer los árboles sin límite y solo se midió su desempeño en prueba, nunca la brecha contra entrenamiento. Además se exploraron cinco configuraciones elegidas a mano, no una búsqueda sistemática, y las variables de entrada siguen siendo las once seleccionadas en la actividad anterior. Finalmente, los porteros quedan fuera del modelo, de modo que el resultado no cubre al dataset completo.

6. Reproducibilidad

La semilla se recibe con --seed (valor por defecto 42) y se aplica en tres puntos: en random.seed() y np.random.seed() al inicio, en el random_state de la división entrenamiento-prueba y en el random_state del modelo. Se verificó ejecutando dos veces el mismo comando: las tres métricas resultaron idénticas hasta el último decimal. Las versiones de las librerías están fijadas en requirements.txt.

7. Evidencias

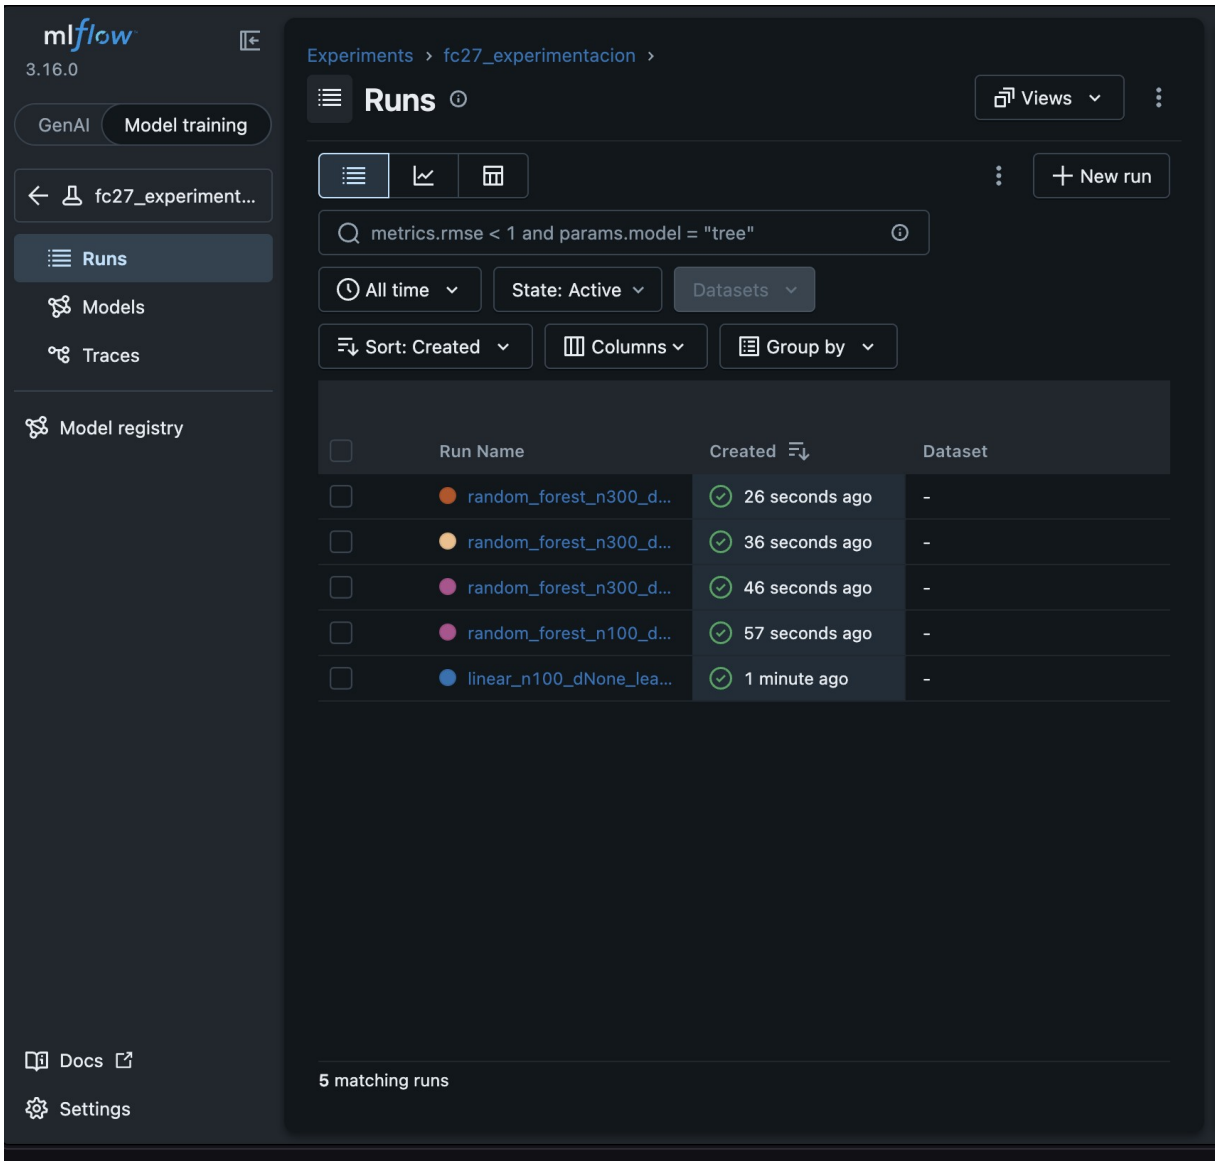


Figura 1. Las cinco corridas agrupadas en el experimento fc27_experimentacion.

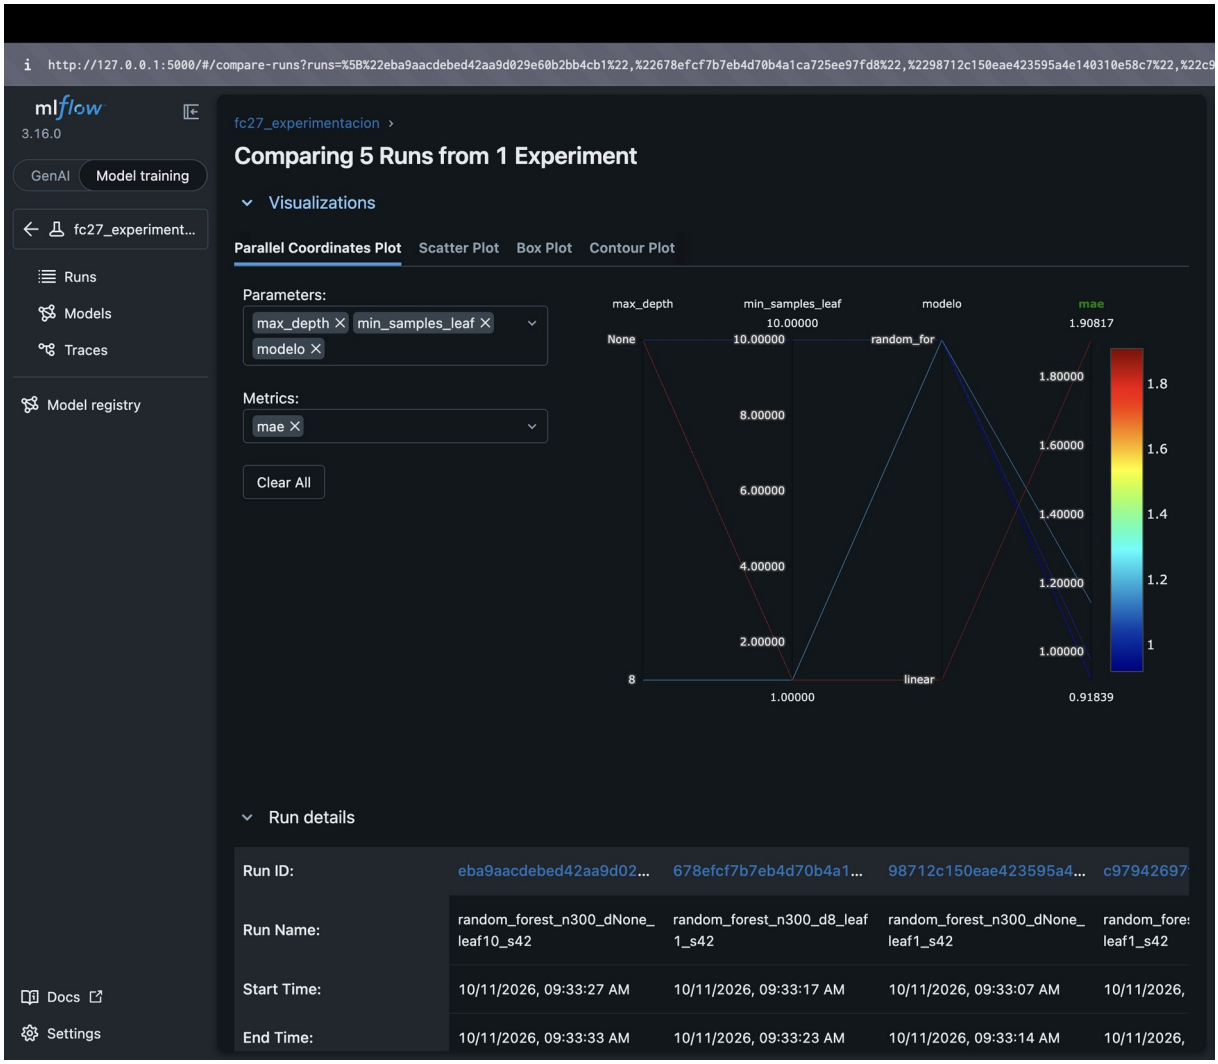


Figura 2. Vista de comparación de MLflow con las cinco corridas. El gráfico de coordenadas paralelas relaciona max_depth, min_samples_leaf y modelo con el MAE resultante, que va de 1.90817 en el baseline lineal a 0.91839 en la mejor configuración.

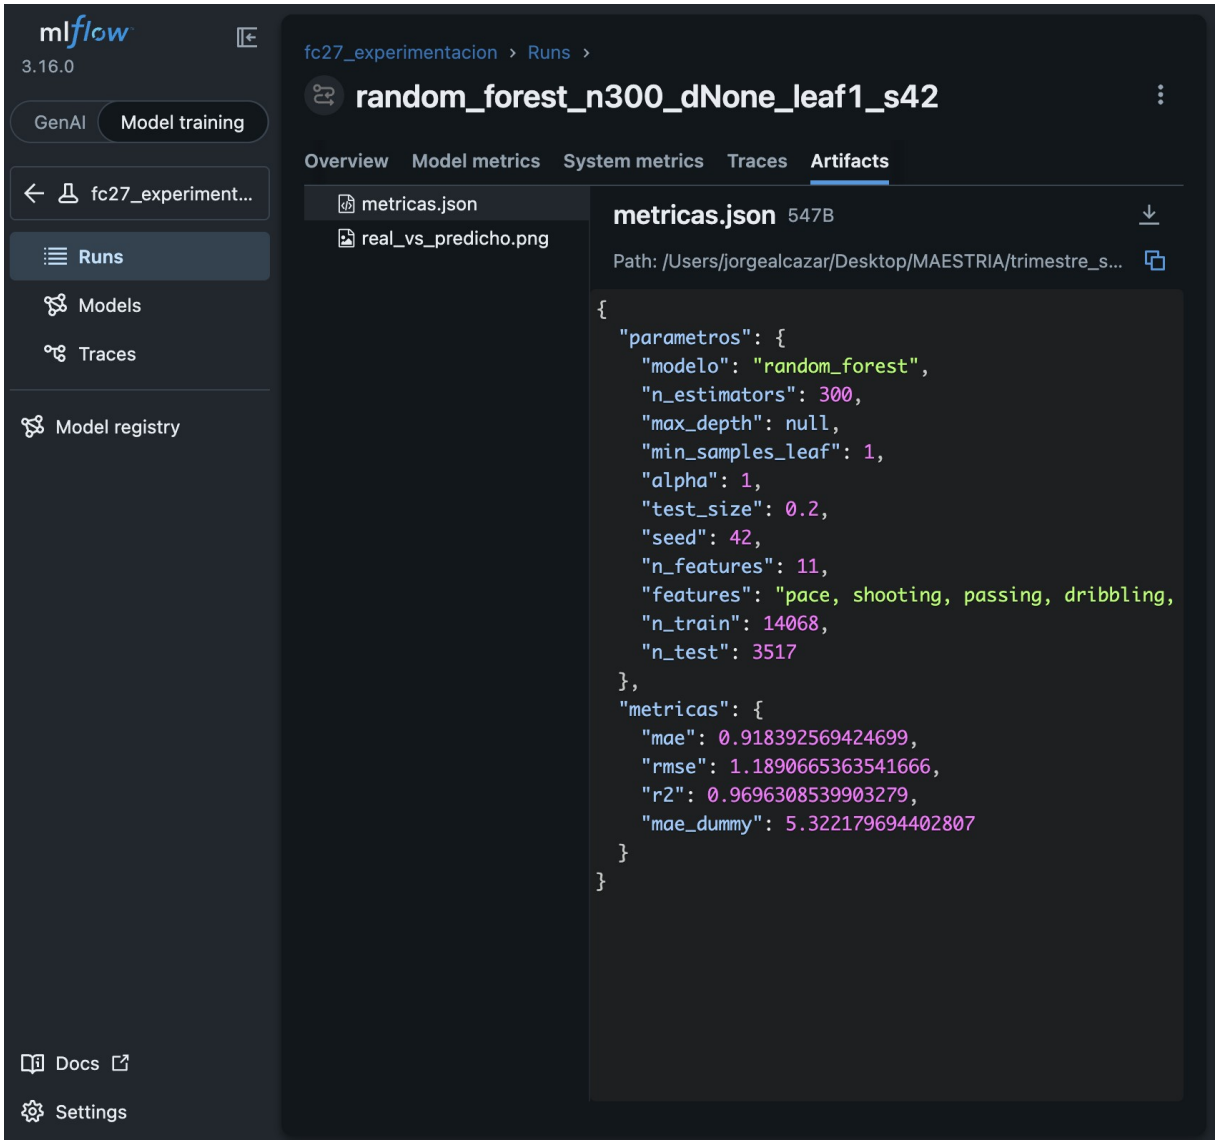


Figura 3. Detalle de la mejor corrida: artefacto metricas.json con los parámetros y las métricas registradas.

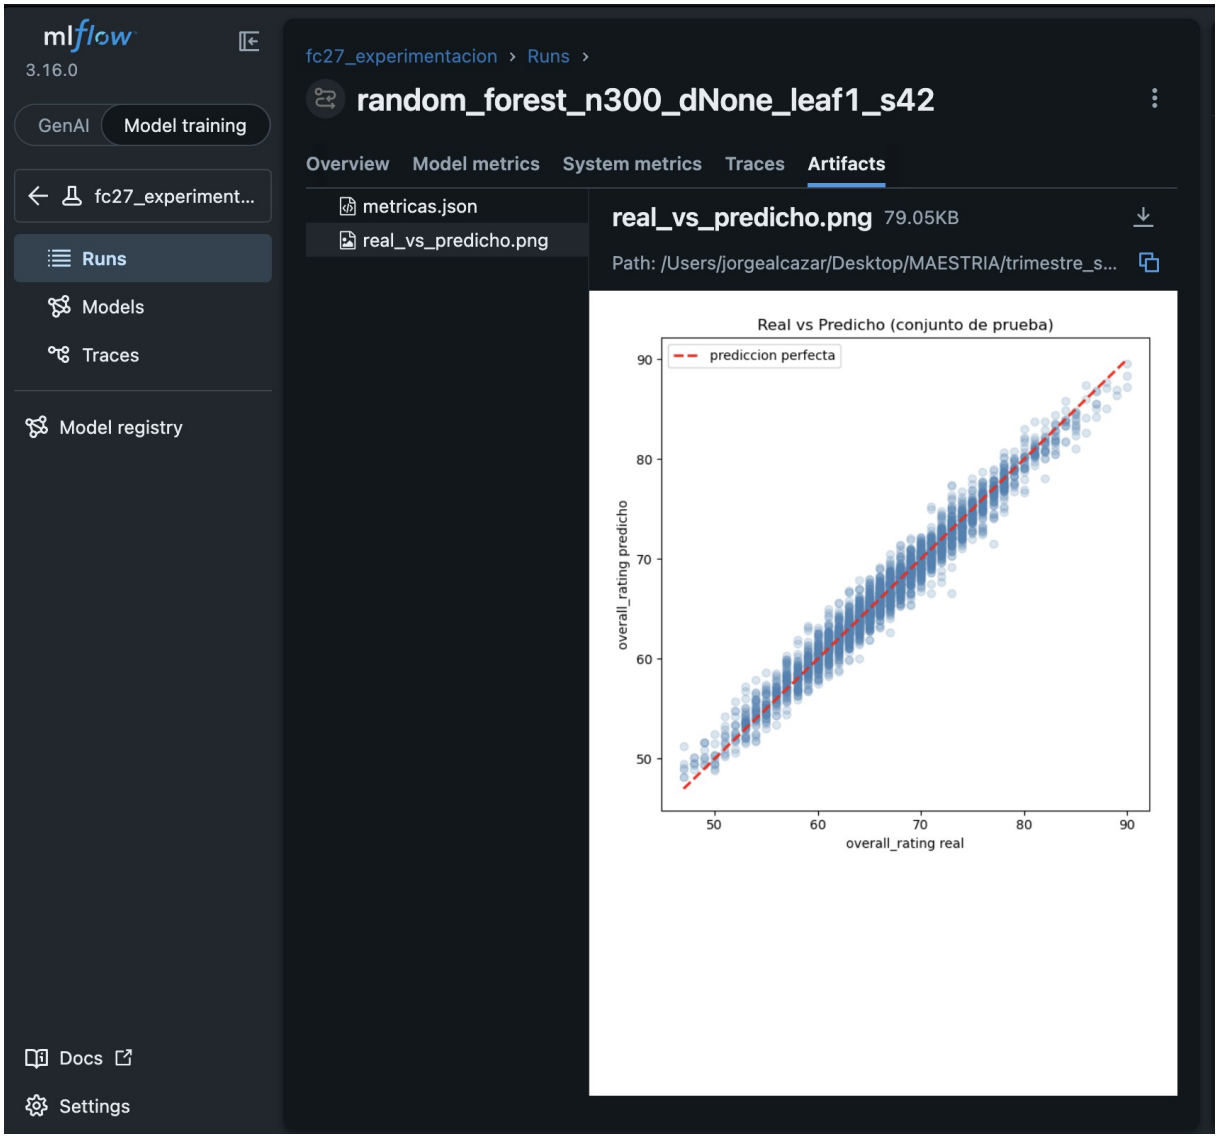


Figura 4. Detalle de la mejor corrida: artefacto real_vs_predicho.png.